

线性回归与模型评估

本次聊天核心知识点总结

一、核心算法：线性回归（监督学习-回归任务）

1. 基础原理

- **核心目标**：建模“特征（自变量）”与“连续型目标变量（因变量）”的线性关系，找到最优拟合线/超平面，最小化预测误差。
- **数学表达式**：
 - 单特征（简单线性回归）： $\hat{y} = wx + b$ （ w =斜率/权重， b =截距/偏置）；
 - 多特征（多元线性回归）： $\hat{y} = w_1x_1 + w_2x_2 + \dots + w_nx_n + b$ （ w_n 为第 n 个特征的权重）。
- **损失函数**：用均方误差（MSE）量化误差，公式为
$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_{\text{true},i} - y_{\text{pred},i})^2$$
（平方放大极端误差，便于优化）。
- **参数求解**：
 - 解析解（最小二乘法）：直接通过公式 $\mathbf{w}^* = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$ 计算最优权重，适合低维数据；
 - 迭代解（梯度下降）：沿损失函数负梯度更新参数，适合高维/大数据（需手动设置学习率 α 控制步长）。

2. 关键参数与扩展

- **模型参数（LinearRegression类）**：
 - `fit_intercept=True/False`：是否计算截距 b （默认True，适合多数场景；False强制过原点，仅用于“ $x=0$ 时 y 必为0”的场景，如“重量→质量”预测）；
 - `n_jobs=None/-1`：并行计算核心数（默认None=单核心；-1=用所有CPU核心，加速大数据训练）；
 - `normalize=False`：是否自动标准化特征（默认False，推荐手动用 `StandardScaler` 预处理，更灵活）。
- **正则化扩展（解决过拟合）**：
 - 岭回归（L2正则化）：损失函数加权重平方和惩罚，避免权重过大，无特征选择功能；

- Lasso回归（L1正则化）：损失函数加权重绝对值和惩罚，可使部分权重为0，实现自动特征选择。

二、工具库：Scikit-learn (sklearn) 核心用法

1. 核心功能模块与常用工具

模块	功能	关键类/函数
<code>sklearn.linear_model</code>	线性模型（回归/分类）	<code>LinearRegression</code> （线性回归）、 <code>Ridge</code> （岭回归）、 <code>Lasso</code> （L1回归）
<code>sklearn.metrics</code>	模型评估	<code>mean_squared_error</code> （MSE）、 <code>r2_score</code> （R ² ）
<code>sklearn.model_selection</code>	数据划分与调优	<code>train_test_split</code> （划分训练/测试集）、 <code>cross_val_score</code> （交叉验证）
<code>sklearn.preprocessing</code>	数据预处理	<code>StandardScaler</code> （标准化）、 <code>MinMaxScaler</code> （归一化）

2. 典型工作流程（以房价预测为例）

1. **数据准备**：加载数据→划分特征（X）与目标（y）；
2. **预处理**：标准化/归一化（可选）→格式转换（适配模型输入）；
3. **模型训练**：初始化 `LinearRegression` →调用 `fit(X_train, y_train)` 训练；
4. **预测与评估**： `predict(X_test)` 生成预测值→用MSE/R²评估效果；
5. **参数提取**： `model.coef_`（权重）、 `model.intercept_`（截距）。

三、工具库：Matplotlib（绘图与中文显示问题）

1. 核心绘图功能

- **子图创建**： `plt.subplot(行, 列, 当前子图索引)`（索引从1开始），如 `plt.subplot(211)` 表示“2行1列布局的第1个子图”；
- **基础绘图**： `plt.scatter(x,y)`（散点图，看原始数据分布）、 `plt.plot(x,y_pred)`（线图，画拟合线）、 `plt.figure(figsize=(w,h))`（设置画布大小）。

2. 中文与负号显示问题解决

- **中文显示警告：**默认字体 `DejaVu Sans` 不支持中文，需手动指定中文字体：

Code block

```
1 plt.rcParams["font.family"] = ["SimHei", "Microsoft YaHei"] # Windows自带中文字体
```

- **负号显示异常：**部分中文字体不支持Unicode负号，需改用ASCII负号：

Code block

```
1 plt.rcParams["axes.unicode_minus"] = False
```

四、数据处理：生成与格式转换（Pandas/Numpy）

1. CSV数据生成（模拟房价数据）

- **需求：**生成含“区域收入、房龄、房间数、人口、房屋面积（Size）、房价（Price）”的结构化数据；
- **核心逻辑：**用 `numpy.random.normal` 生成符合正态分布的模拟特征，通过“线性组合+随机噪声”模拟房价，最后用 `pandas.DataFrame.to_csv` 保存为CSV文件。

2. 数组格式转换（reshape, 适配模型输入）

- **核心需求：**sklearn模型要求特征输入为**二维数组（样本数×特征数）**，需将一维特征转换为二维。
- **关键语法与意义：**
 - `x.reshape(-1, 1)`：一维→二维列向量（如 `(4,)` → `(4,1)`），`-1` 表示“自动计算行数”；
 - `x.reshape(1, -1)`：一维→二维行向量（如 `(4,)` → `(1,4)`）；
 - `x.reshape(-1,1,1)`：一维→三维数组（如 `(4,)` → `(4,1,1)`），用于深度学习时序/图像模型。

五、模型评估：回归任务关键指标

1. 均方误差（MSE, `mean_squared_error`）

- **意义：**衡量预测值与真实值的平均偏差程度，**值越小，拟合效果越好**；

- 用法: `sklearn.metrics.mean_squared_error(y_true, y_pred)` (y_{true} =真实值, y_{pred} =预测值)。

2. 决定系数 (R^2 , `r2_score`)

- 意义: 衡量模型对“目标变量变异”的解释能力, 取值范围 $(-\infty, 1]$, 越接近1, 模型解释能力越强;
- 特殊值: $R^2=0$ →模型效果=“直接预测目标均值”; $R^2<0$ →模型效果差于“预测均值”;
- 用法: `sklearn.metrics.r2_score(y_true, y_pred)`。

六、Python模块导入方式

1. 两种核心导入方式对比

导入方式	语法示例	适用场景
逐个导入特定函数	<pre>from sklearn.metrics import mean_squared_error, r2_score</pre>	仅用少数函数, 代码简洁
导入整个模块 (加别名)	<pre>import sklearn.metrics as metrics</pre>	用多个函数, 避免函数名冲突, 清晰追溯来源

2. 选择建议

- 用1-2个函数: 选“逐个导入”;
- 用3个以上函数: 选“导入整个模块+别名” (如 `import sklearn.metrics as metrics`, 调用时 `metrics.MSE`)。

(注: 文档部分内容可能由 AI 生成)