

多因子线性回归：特征与预测

多因子线性回归核心知识点与代码实践总结

一、数据准备：特征与目标分离

在多因子线性回归中，需将数据集拆分为**自变量（多特征集合）**和**因变量（待预测目标）**：

Code block

```
1 # 从DataFrame中删除因变量列，得到多特征自变量 (X_multi)
2 X_multi = data.drop(['Price'], axis=1)
3 # 提取因变量 (y)
4 y = data['Price']
```

- `axis=1` 表示**按列操作**，确保删除 “Price” 列后保留所有特征列。

二、模型训练：多特征联合训练

使用 `sklearn` 的 `LinearRegression` 实现多特征线性回归训练：

Code block

```
1 from sklearn.linear_model import LinearRegression
2
3 # 初始化线性回归模型
4 LR_multi = LinearRegression()
5 # 用多特征 (X_multi) 和目标 (y) 训练模型
6 LR_multi.fit(X_multi, y)
```

- 模型会学习**多个特征对目标的联合影响**（每个特征对应一个“权重系数”）。

三、预测：特征名称匹配原则

模型训练时若用**带特征名的 DataFrame**（如 `X_multi` 是列名明确的 DataFrame），预测时需保证输入数据的**特征名称/结构与训练时一致**，否则会触发 Sklearn 警告。

错误示例（触发警告）：

Code block

```
1 # 构造无特征名的 numpy 数组
2 X_test_np = np.array([[65000, 5, 5, 30000, 200]])
```

```
3 # 因无特征名，与训练环境（带特征名 DataFrame）不一致，触发警告
4 y_pred = LR_multi.predict(X_test_np)
```

正确做法（保持特征名一致）：

将测试数据转换为**列名与训练数据一致的 DataFrame**后预测：

Code block

```
1 import pandas as pd
2
3 # 定义与训练数据一致的特征名
4 feature_names = ['Avg. Area Income', 'Avg. Area House Age',
5                  'Avg. Area Number of Rooms', 'Area Population', 'Size']
6 # 将 numpy 数组转换为带特征名的 DataFrame
7 X_test_df = pd.DataFrame(X_test_np, columns=feature_names)
8 # 用 DataFrame 预测，无警告且特征匹配更安全
9 y_pred = LR_multi.predict(X_test_df)
```

四、预测结果解读

`predict` 方法返回**预测值数组**，每个元素对应一个样本的预测结果（如房价）：

Code block

```
1 # 对数据（如训练/测试数据）进行预测
2 y_predict_multi = LR_multi.predict(X_data)
3 print(y_predict_multi) # 输出预测值数组
```

关键原则总结

1. **特征一致性**：训练和预测时，特征的**数量、顺序、名称**需完全一致（用 DataFrame 并保持列名一致最安全）。
2. **多特征联合性**：多因子线性回归的核心是**多个特征共同影响目标**，模型学习每个特征的“权重系数”量化其影响。
3. **Sklearn 警告本质**：训练时依赖“特征名称”（如 DataFrame 列名），若预测数据丢失该信息（如转成无特征名的 numpy 数组）会触发警告；为严谨性，建议保持特征名一致。

（注：文档部分内容可能由 AI 生成）