

逻辑回归：从基础到扩展

逻辑回归：从基础到扩展

一、逻辑回归的定位与本质

逻辑回归是机器学习中基础且常用的分类算法，虽名称含“回归”，但核心用于二分类任务（也可通过扩展支持多分类）。与线性回归的核心区别：

- 线性回归输出连续值（如预测房价、销售额）；
- 逻辑回归输出离散类别或类别概率（如“用户购买的概率为80%”）。

二、数学原理：从线性关系到概率映射

逻辑回归通过“对数几率的线性假设”，将特征与“正类概率”关联，核心步骤如下：

1. 线性得分计算

先对输入特征做线性组合，得到“线性得分”（ z ）（形式与线性回归一致）：

$$z = g(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \cdots + \theta_n x_n$$

其中， $x_1, x_2, \dots, x_n$ 为输入特征， $\theta_0, \theta_1, \dots, \theta_n$ 为待学习的参数（权重与偏置）。

2. Sigmoid函数：概率的映射工具

线性得分 (z) 的取值范围是 $(-\infty, +\infty)$ ，无法直接表示“概率”（概率需满足 $0 \leq P \leq 1$ ）。因此引入Sigmoid函数，将 z 映射到 $(0, 1)$ 区间，得到“样本属于正类 ($y = 1$) 的概率”

$P(y = 1 | x)$ ：

$$P(y = 1 | x) = \frac{1}{1 + e^{-z}}$$

Sigmoid函数的关键特性：

- 当 $z \rightarrow +\infty$ 时， $P(y = 1 | x) \rightarrow 1$ （大概率为正类）；
- 当 $z \rightarrow -\infty$ 时， $P(y = 1 | x) \rightarrow 0$ （大概率为负类）；
- 当 $z = 0$ 时， $P(y = 1 | x) = 0.5$ （分类阈值点）。

3. 对数几率的线性假设

逻辑回归的核心假设是：正类的“对数几率（Log Odds）”与特征呈线性关系。

- 几率（Odds）：正类概率与负类概率的比值，即 $\text{Odds} = \frac{P(y = 1 | x)}{1 - P(y = 1 | x)}$ ；
- 对数几率：对“几率”取自然对数，即 $\ln \left(\frac{P(y = 1 | x)}{1 - P(y = 1 | x)} \right)$ 。

结合线性得分 $z = g(x)$ ，假设可表示为：

$$\ln \left(\frac{P(y = 1 | x)}{1 - P(y = 1 | x)} \right) = g(x)$$

通过数学推导（两边取指数后解方程），可反向得到Sigmoid函数形式的概率表达式，这也解释了“为何用Sigmoid映射概率”。

三、损失函数与优化：最小化预测偏差

1. 对数损失（Log Loss）

由于均方误差（MSE）会导致损失函数“非凸”（存在多个局部最小值，无法用梯度下降找全局最优），逻辑回归使用对数损失衡量“预测概率”与“真实标签”的差距。

对于单个样本，若真实标签为 y_i （ $y_i = 1$ 为正类， $y_i = 0$ 为负类），预测概率为 $P(x_i)$ ，则单个样本的损失为：

$J_i = \begin{cases}$

$-\log(P(x_i)), & \text{若 } y_i = 1 \\$

$-\log(1 - P(x_i)), & \text{若 } y_i = 0$

$\end{cases}$

对所有 m 个样本，总损失（取平均后）为：

$$J = -\frac{1}{m} \sum_{i=1}^m [y_i \log(P(x_i)) + (1 - y_i) \log(1 - P(x_i))]$$

2. 梯度下降法：优化参数的核心工具

逻辑回归通过梯度下降法最小化总损失 J ，求解最优参数 θ 。梯度下降的核心逻辑是：

- 计算损失函数对每个参数 θ_j 的梯度（即偏导数 $\frac{\partial J}{\partial \theta_j}$ ，表示损失上升最快的方向）；
- 沿着梯度的反方向调整参数（目的是让损失下降），参数更新公式为：

$$\theta_j = \theta_j - \alpha \cdot \frac{\partial J}{\partial \theta_j}$$

其中， α 是“学习率”，控制每一步调整的“步长”（步长过大易跳过最优解，过小则训练过慢）。

重复上述更新过程，直到参数变化极小（“收敛”），此时损失接近最小值，模型参数也达到最优。

四、扩展与优化：正则化与多分类

1. 正则化：解决过拟合

当模型过于复杂（如特征数远大于样本数），易出现“过拟合”（训练集表现好、测试集表现差）。逻辑回归常用**L1正则化（Lasso）**和**L2正则化（Ridge）**限制参数大小：

- L1正则化：在损失函数中加入“参数绝对值之和”，会让部分参数变为0（实现“特征筛选”）：

$$J_{L1} = J + \lambda \sum_{j=1}^n |\theta_j|$$

- L2正则化：在损失函数中加入“参数平方和”，使参数整体变小（不剔除特征，仅削弱特征影响）：

$$J_{L2} = J + \frac{\lambda}{2} \sum_{j=1}^n \theta_j^2$$

其中， λ 为“正则化强度”，越大则参数约束越强。

2. 多分类扩展

逻辑回归默认是二分类，但可通过以下方式扩展到多分类：

- 一对多（One-vs-Rest）：对每个类别，训练“该类别 vs 其他所有类别”的二分类器，最终取概率最大的类别；
- Softmax回归：直接建模多类别概率分布，输出每个类别对应的概率（是逻辑回归在多分类场景的推广）。

五、优缺点与应用场景

1. 优点

- 简单高效：模型参数少，训练速度快，适合大规模数据；
- 可解释性强：参数 θ_j 的正负和大小，能直观解释“特征对正类的影响方向与程度”；
- 输出概率明确：直接输出类别概率，便于业务决策（如“用户购买概率70%”）；
- 鲁棒性较好：对噪声不敏感，无需严格假设特征线性相关（可通过特征工程弥补）。

2. 缺点

- 非线性处理能力弱：本质是线性模型，若特征与标签呈非线性关系，需手动做“特征工程”（如添加多项式、交互特征）；
- 对异常值敏感：异常值会干扰线性得分的计算，需提前处理；
- 多分类效果有限：相比专门的多分类算法（如随机森林），二分类外的表现一般。

3. 典型应用场景

- 二分类任务：信用违约预测（判断用户是否违约）、医疗诊断（判断是否患病）、垃圾邮件过滤、营销响应预测（判断用户是否点击广告）；

- 多分类扩展：手写数字识别（如MNIST数据集）、文本分类（如新闻类别划分）。

六、总结

逻辑回归是“简单但强大”的分类算法，核心优势在于可解释性与高效性，适合作为机器学习入门或工业界“基线模型”（先验证问题可行性，再用复杂模型优化）。其局限性可通过特征工程、正则化或与其他算法结合来弥补，是分类任务中不可或缺的工具。

要不要我帮你生成一份**带完整数学符号的PDF版本文档**，方便你离线查看和学习？

（注：文档部分内容可能由 AI 生成）