

逻辑回归：从基础到扩展

逻辑回归核心知识点总结文档

一、逻辑回归的定位与本质

逻辑回归是机器学习中**基础且常用的分类算法**，虽名称含“回归”，但核心用于**二分类任务**（也可通过扩展支持多分类）。与线性回归的核心区别：

- 线性回归输出**连续值**（如预测房价、销售额）；
- 逻辑回归输出**离散类别或类别概率**（如“用户购买的概率为80%”）。

二、数学原理：从线性关系到概率映射

逻辑回归通过“**对数几率的线性假设**”，将特征与“正类概率”关联，核心步骤如下：

1. 线性得分计算

先对输入特征做线性组合，得到“线性得分” (z) （形式与线性回归一致）：

$$[z = g(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \dots + \theta_n x_n]$$

其中， $(x_1, x_2, \dots, x_n)$ 为输入特征， $(\theta_0, \theta_1, \dots, \theta_n)$ 为待学习的参数（权重与偏置）。

2. Sigmoid函数：概率的映射工具

线性得分 (z) 的取值范围是 $(-\infty, +\infty)$ ，无法直接表示“概率”（概率需满足 $0 \leq P \leq 1$ ）。因此引入**Sigmoid函数**，将 (z) 映射到 $(0,1)$ 区间，得到“样本属于正类 $(y=1)$ 的概率” $(P(y=1 \mid x))$ ：

$$[P(y=1 \mid x) = \frac{1}{1 + e^{-z}}]$$

Sigmoid函数的关键特性：

- 当 $(z \rightarrow +\infty)$ 时， $(P(y=1 \mid x) \rightarrow 1)$ （大概率为正类）；
- 当 $(z \rightarrow -\infty)$ 时， $(P(y=1 \mid x) \rightarrow 0)$ （大概率为负类）；
- 当 $(z = 0)$ 时， $(P(y=1 \mid x) = 0.5)$ （分类阈值点）。

3. 对数几率的线性假设

逻辑回归的核心假设是：**正类的“对数几率（Log Odds）”与特征呈线性关系**。

- 「几率 (Odds)」：正类概率与负类概率的比值，即 $(\text{Odds} = \frac{P(y=1 \mid x)}{1 - P(y=1 \mid x)})$;
- 「对数几率」：对“几率”取自然对数，即 $(\ln(\frac{P(y=1 \mid x)}{1 - P(y=1 \mid x)}))$ 。

结合线性得分 $(z = g(x))$ ，假设可表示为：

$$\ln(\frac{P(y=1 \mid x)}{1 - P(y=1 \mid x)}) = g(x)$$

通过数学推导（两边取指数后解方程），可反向得到Sigmoid函数形式的概率表达式，这也解释了“为何用Sigmoid映射概率”。

三、损失函数与优化：最小化预测偏差

1. 对数损失 (Log Loss)

由于均方误差 (MSE) 会导致损失函数“非凸”（存在多个局部最小值，无法用梯度下降找全局最优），逻辑回归使用**对数损失**衡量“预测概率”与“真实标签”的差距。

对于单个样本，若真实标签为 (y_i) ($y_i=1$ 为正类， $y_i=0$ 为负类)，预测概率为 $(P(x_i))$ ，则单个样本的损失为：

$$J_i = \begin{cases} -\log(P(x_i)), & \text{若 } y_i = 1 \\ -\log(1 - P(x_i)), & \text{若 } y_i = 0 \end{cases}$$

对所有 (m) 个样本，总损失（取平均后）为：

$$J = -\frac{1}{m} \sum_{i=1}^m [y_i \log(P(x_i)) + (1 - y_i) \log(1 - P(x_i))]$$

2. 梯度下降法：优化参数的核心工具

逻辑回归通过**梯度下降法**最小化总损失 (J) ，求解最优参数 (θ) 。梯度下降的核心逻辑是：

- 计算损失函数对每个参数 (θ_j) 的**梯度**（即偏导数 $(\frac{\partial J}{\partial \theta_j})$ ），表示损失上升最快的方向；
- 沿着梯度的**反方向**调整参数（目的是让损失下降），参数更新公式为：

$$\theta_j = \theta_j - \alpha \cdot \frac{\partial J}{\partial \theta_j}$$

其中， (α) 是“学习率”，控制每一步调整的“步长”（步长过大易跳过最优解，过小则训练过慢）。

重复上述更新过程，直到参数变化极小（“收敛”），此时损失接近最小值，模型参数也达到最优。

四、扩展与优化：正则化与多分类

1. 正则化：解决过拟合

当模型过于复杂（如特征数远大于样本数），易出现“过拟合”（训练集表现好、测试集表现差）。逻辑回归常用**L1正则化（Lasso）和L2正则化（Ridge）**限制参数大小：

- **L1正则化**：在损失函数中加入“参数绝对值之和”，会让部分参数变为0（实现“特征筛选”）：

$$J_{\text{L1}} = J + \lambda \sum_{j=1}^n |\theta_j|$$

- **L2正则化**：在损失函数中加入“参数平方和”，使参数整体变小（不剔除特征，仅削弱特征影响）：

$$J_{\text{L2}} = J + \frac{\lambda}{2} \sum_{j=1}^n \theta_j^2$$

((λ) 为“正则化强度”，越大则参数约束越强)

2. 多分类扩展

逻辑回归默认是二分类，但可通过以下方式扩展到多分类：

- **一对多（One-vs-Rest）**：对每个类别，训练“该类别 vs 其他所有类别”的二分类器，最终取概率最大的类别；
- **Softmax回归**：直接建模多类别概率分布，输出每个类别对应的概率（是逻辑回归在多分类场景的推广）。

五、优缺点与应用场景

1. 优点

- **简单高效**：模型参数少，训练速度快，适合大规模数据；
- **可解释性强**：参数(θ_j)的正负和大小，能直观解释“特征对正类的影响方向与程度”；
- **输出概率明确**：直接输出类别概率，便于业务决策（如“用户购买概率70%”）；
- **鲁棒性较好**：对噪声不敏感，无需严格假设特征线性相关（可通过特征工程弥补）。

2. 缺点

- **非线性处理能力弱**：本质是线性模型，若特征与标签呈非线性关系，需手动做“特征工程”（如添加多项式、交互特征）；
- **对异常值敏感**：异常值会干扰线性得分的计算，需提前处理；
- **多分类效果有限**：相比专门的多分类算法（如随机森林），二分类外的表现一般。

3. 典型应用场景

- **二分类任务**：信用违约预测（判断用户是否违约）、医疗诊断（判断是否患病）、垃圾邮件过滤、营销响应预测（判断用户是否点击广告）；
- **多分类扩展**：手写数字识别（如MNIST数据集）、文本分类（如新闻类别划分）。

六、总结

逻辑回归是“简单但强大”的分类算法，核心优势在于**可解释性与高效性**，适合作为机器学习入门或工业界“基线模型”（先验证问题可行性，再用复杂模型优化）。其局限性可通过特征工程、正则化或与其他算法结合来弥补，是分类任务中不可或缺的工具。

（注：文档部分内容可能由 AI 生成）