

机器学习核心算法与概念总结

机器学习核心算法与概念总结文档

一、决策树与特征选择指标

决策树是一种**可解释性强**的监督学习算法，通过“递归拆分数据”实现分类或回归。核心是“特征选择指标”——用于确定“最优拆分特征”，推动树的构建。

（一）ID3算法

- 核心思想**：基于**信息增益**选择最优特征，递归构建决策树（仅支持分类任务）。
- 信息熵 (Entropy)**：衡量数据“不确定性”的指标。公式：

$$H(D) = - \sum_{i=1}^k p_i \log_2 p_i$$

其中 (p_i) 是第 (i) 类样本在数据集 (D) 中的占比；熵值越低，数据越“纯”。

- 信息增益 (Information Gain)**：拆分前的熵与拆分后“条件熵”的差值，衡量特征对“降低不确定性”的贡献。公式：

$$\text{Gain}(D, A) = H(D) - H(D|A)$$

其中 ($H(D|A)$) 是用特征 (A) 拆分后的条件熵（加权平均各子集的熵）。

- 局限性**：偏好“多取值特征”（如“身份证号”这类无意义但取值多的特征易被优先选择）；不支持连续值、缺失值。

（二）信息增益比 (Information Gain Ratio)

- 提出背景**：解决ID3对“多取值特征”的偏好，是**C4.5算法**的核心指标。
- 公式**：

$$\text{Gain_ratio}(D, A) = \frac{\text{Gain}(D, A)}{\text{IV}(A)}$$

其中 $(\text{IV}(A))$ 是特征 (A) 的**固有值**（衡量特征自身取值的分布复杂度）。

- **特征固有值 (Intrinsic Value)**：公式：

$$\text{IV}(A) = - \sum_{i=1}^v \frac{|D_i|}{|D|} \log_2 \frac{|D_i|}{|D|}$$

其中 (v) 是特征 (A) 的取值数量， (D_i) 是特征 (A) 取第 (i) 个值的样本子集；固有值越大，特征取值越分散。

(三) Gini系数 (Gini Impurity)

- **核心思想**：衡量数据集的“纯度”——随机选择一个样本，被误分类到其他类别的概率（是**CART**算法的核心指标，支持分类和回归）。
- **公式**：

$$\text{Gini}(D) = 1 - \sum_{i=1}^k p_i^2$$

其中 (p_i) 是第 (i) 类样本的占比；Gini系数越小，数据越“纯”。

- **决策树应用**：选择“拆分后子节点Gini系数加权和最小”的特征，加权和公式：

$$\text{Gini_index}(D, A) = \sum_{i=1}^v \frac{|D_i|}{|D|} \cdot \text{Gini}(D_i)$$

二、异常检测

异常检测旨在识别数据中不符合“正常模式”的样本（异常样本可能是噪声或有意义的特殊事件，如欺诈、故障）。因异常标签稀缺，实际以无监督/半监督方法为主。

(一) 基于高斯分布的异常检测

- **假设**：正常样本服从高斯分布，异常样本显著偏离该分布。
- **多维联合概率密度**：若各维度**统计独立**，联合概率密度为“各维度边缘概率密度的乘积”。公式：

$$p(\boldsymbol{x}) = \prod_{j=1}^n p(x_j; \mu_j, \sigma_j^2) = \prod_{j=1}^n \frac{1}{\sigma_j \sqrt{2\pi}} e^{-\frac{(x_j - \mu_j)^2}{2\sigma_j^2}}$$

其中 (μ_j, σ_j^2) 是第 (j) 维的均值、方差；“边缘概率密度”指**单个维度**的概率密度。

（二）典型无监督异常检测算法

算法	核心原理	适用场景
LOF（局部异常因子）	衡量样本“局部密度”：异常样本的局部密度远低于邻居，LOF值远大于1则为异常。	任意形状分布的数据（如非球形簇）
自编码器（Autoencoder）	用神经网络学习“正常样本的重构模式”，异常样本重构误差（如MSE）极大。	高维数据（如图像、时序数据）
孤立森林（Isolation Forest）	随机划分特征空间“孤立”异常样本：异常样本因数量少、偏离主流，更易被快速孤立。	高维、大规模数据集

（三）评估指标

因数据**极度不平衡**（异常样本占比极低），传统“准确率”失效，需用关注“异常识别能力”的指标：

- 精确率（Precision）： $(\text{Precision} = \frac{TP}{TP + FP})$ ——被预测为异常的样本中，真正异常的比例（控制误检率）。
- 召回率（Recall）： $(\text{Recall} = \frac{TP}{TP + FN})$ ——真实异常中，被成功检测的比例（控制漏检率）。
- F1分数： $(\text{F1} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}})$ ——平衡精确率与召回率。
- AUC-ROC：ROC曲线下面积——衡量模型“区分正常与异常”的整体能力，越接近1性能越好。

三、主成分分析（PCA）

PCA是**无监督降维算法**，通过“线性变换”将高维数据映射到低维空间，同时**保留最多的原始信息**（用“方差”衡量信息含量）。

（一）核心思想

找到一组**正交的新维度（主成分）**，使数据在这些维度上的“投影方差最大”，且主成分间线性无关（协方差为0）。

（二）数学推导步骤

1. **数据中心化**：对每个特征减去均值，得到 $\tilde{\mathbf{x}}_i = \mathbf{x}_i - \boldsymbol{\mu}$ （ $\boldsymbol{\mu}$ 为均值向量）。

2. **协方差矩阵**：计算中心化后数据的协方差矩阵：

$$\boldsymbol{\Sigma} = \frac{1}{n} \sum_{i=1}^n \tilde{\mathbf{x}}_i \tilde{\mathbf{x}}_i^T$$

3. **特征值分解**：对协方差矩阵 $\boldsymbol{\Sigma}$ 做特征值分解，得到**特征值** λ_i 和**特征向量** $\mathbf{u}_i$ ；特征值越大，对应主成分的“方差越大”（越重要）。

4. **选择主成分**：选取“前 k 个最大特征值”对应的特征向量，组成**投影矩阵** $\mathbf{W}_k$ （ $k \ll d$ ， d 为原始维度）。

5. **降维投影**：中心化后的数据 $\tilde{\mathbf{X}}$ 与投影矩阵相乘，得到降维后的数据：

$$\mathbf{Y} = \tilde{\mathbf{X}} \mathbf{W}_k$$

（三）优缺点与扩展

- 优点**：有效降维去冗余、可解释性强、计算稳定；适用于数据可视化、特征提取、噪声过滤等。
- 缺点**：线性假设（对非线性数据效果差）、对异常敏感、依赖量纲（需标准化）。
- 扩展算法**：
 - 核PCA：通过“核函数”将数据映射到高维空间后做PCA，处理**非线性数据**。

- 增量PCA：迭代更新方式处理**大规模数据**（无需一次性加载全量数据）。
- 稀疏PCA：通过L1正则化强制主成分仅包含少数特征，**提升解释性**。

以上内容涵盖了决策树、异常检测、PCA的核心原理、数学公式与应用场景，可作为机器学习基础理论的总结参考。

（注：文档部分内容可能由 AI 生成）