

机器学习基础工具与方法总结

机器学习基础工具与方法知识点总结

一、决策树分类器 (`DecisionTreeClassifier`)

(一) 核心参数

- `criterion`：节点分裂的“不纯度度量标准”，可选 `'entropy'`（信息熵，类似ID3算法的“信息增益”）或 `'gini'`（基尼系数，默认）。注意：scikit-learn 决策树基于 **CART算法**，不直接支持C4.5的“信息增益比”。
- `min_samples_leaf`：叶子节点的**最小样本数**（分裂后子节点样本数需 $\geq$ 该值，防止过拟合）。
- `max_depth`：树的**最大深度**（限制树的复杂度，避免过拟合）。
- `min_samples_split`：节点分裂所需的**最小样本数**（节点样本数 $\geq$ 该值才会尝试分裂）。
- `max_features`：分裂时考虑的**最大特征数**（控制随机性、提升泛化能力，如 `'sqrt'` 表示取“特征数的平方根”）。
- `class_weight`：类别权重（解决“类别不平衡”问题，可选 `'balanced'` 或自定义权重字典）。

(二) 决策树可视化 (`tree.plot_tree`)

通过 `sklearn.tree.plot_tree` 可视化决策树结构，关键参数：

- `filled=True`：为节点填充颜色（颜色深浅反映节点“不纯度”，纯度越高颜色越深）。
- `feature_names` / `class_names`：指定**特征名称**和**类别名称**（提升可视化可读性，如鸢尾花数据集的“花萼长度”“setosa”等）。
- `max_depth`：限制显示的树深度（简化复杂树的可视化，聚焦关键分裂逻辑）。

- `fontsize`：调整节点内文字大小（提升密集树结构的可读性）。

二、数据分布与统计分析

（一）直方图与分布可视化

- `plt.hist(x, bins=100)`：绘制数据 `x` 的直方图，`bins` 指定“区间数量”（值越大，区间划分越细，分布细节越清晰）。

（二）连续序列生成

- `np.linspace(start, stop, num)`：生成 `num` 个在 `[start, stop]` 区间内均匀分布的点（用于绘制连续曲线，如正态分布PDF）。

与Python内置 `range` 的区别：`range` 生成整数序列且“不包含终止值”；`np.linspace` 生成浮点序列且“默认包含终止值”。

（三）正态分布与统计量

- 均值与标准差：`x.mean()` 计算数据均值（反映中心趋势），`x.std()` 计算标准差（反映离散程度）。
- 正态分布PDF：`scipy.stats.norm.pdf(x, loc, scale)` 计算“正态分布在 `x` 处的概率密度值”（`loc` 为均值，`scale` 为标准差），用于对比“实际数据分布”与“理论正态分布”。

三、异常检测（`EllipticEnvelope`）

（一）核心原理

假设“正常数据服从椭圆分布（如多元正态分布）”，通过**马氏距离**判断样本是否在“正常分布边界（椭圆）”内，超出边界则判定为异常。

（二）关键参数

- `contamination`：预设**异常值比例**（范围 `(0, 0.5)`），如 `0.02` 表示预计2%的数据为异常），模型据此调整“异常判断阈值”。
- `covariance_estimator`：协方差估计器，默认 `MinCovDet`（**稳健估计**，对训练数据中的异常值不敏感，适合含异常的场景）。
- `random_state`：随机种子（保证训练/预测结果可复现）。

（三）常用方法

- `fit(data)`：训练模型（学习“正常数据”的分布特征）。
- `predict(data)`：预测样本标签（`1` 表示正常，`-1` 表示异常）。
- `decision_function(data)`：计算“异常分数”（值越小，样本越可能是异常）。

四、数据预处理

（一）标准化（`StandardScaler`）

- **作用**：将特征转换为“均值为0、标准差为1”的分布，消除**量纲差异**（如“身高（cm）”和“体重（kg）”）或**数值范围差异**对后续模型的影响。
- **正确使用方式**：需先**实例化** `StandardScaler`，再调用 `fit_transform`，示例：

Code block

```
1 from sklearn.preprocessing import StandardScaler
2 scaler = StandardScaler()
3 x_norm = scaler.fit_transform(x) # x为原始特征数据
```

（二）PCA前的标准化必要性

PCA 依赖 “**方差最大化**” 寻找主成分，若特征存在以下情况，**必须先标准化**：

- 量纲不同（如 “年龄（岁）” 和 “收入（元）” ）；
- 数值范围差异大（如一个特征取值在 `[0,10]`，另一个在 `[0,10000]` ）。

例外：若所有特征 “量纲一致且数值范围接近” （如多个传感器的 “温度（℃）” ），可跳过标准化。

五、主成分分析（PCA）

（一）核心作用

将**高维数据**映射到**低维 “主成分空间”**，保留数据的 “主要变异信息” （实现降维的同时，减少信息损失）。

（二）关键参数（`sklearn.decomposition.PCA`）

- `n_components`：主成分数量，支持多种设置方式：
 - 整数（如 `n_components=2`，直接降维到2维）；
 - 浮点数（如 `n_components=0.95`，保留 “累计解释方差 $\geq 95\%$ ” 的主成分）；
 - `'mle'` （通过 “最大似然估计” 自动选择主成分数量，仅 `svd_solver='full'` 时有效）。
- `svd_solver`：SVD（奇异值分解）求解器，影响计算效率：
 - `'auto'` （默认，自动选择求解器）；
 - `'full'` （精确SVD，适合小数据集或需精确分解的场景）；
 - `'randomized'` （随机SVD，速度快、内存占用低，适合高维数据）。
- `whiten`：是否 “白化” （使主成分方差为1，消除成分间相关性，适合后续对 “特征方差敏感” 的模型，如SVM）。

（三）核心属性

- `explained_variance_ratio_`：各主成分“解释的方差占总方差的比例”（反映主成分的“信息含量”。如“前2个主成分累计占比90%”，则降维到2维仅损失10%信息）。

以上知识点覆盖了“决策树建模、数据分布分析、异常检测、数据预处理、降维”等机器学习基础流程的关键技术，是从“数据探索”到“模型构建”的核心工具总结。

（注：文档部分内容可能由 AI 生成）