

预装环境下的部署步骤

部署文档（适配预装环境）

0. 登录后第一件事（必做）

关闭 MIG（否则 GPU 用不了）：

Code block

```
1  nvidia-smi -i 0 -mig 0
2  sudo reboot
```

重启后重新登录，验证 GPU：

Code block

```
1  nvidia-smi
2  python -c "import torch; print(torch.cuda.is_available())"
```

输出 `True` 就可以继续。

1. 只装「缺失的依赖」（不用装 PyTorch 了！）

系统已经有 PyTorch，我们只补项目需要的包：

Code block

```
1  # 换清华源（加速）
2  pip config set global.index-url https://pypi.tuna.tsinghua.edu.cn/simple
3
4  # 安装项目依赖（跳过 torch 相关）
5  pip install matplotlib pandas numpy transformers datasets tqdm sentencepiece
   ipywidgets
```

2. 启动 Jupyter 开发（和之前一样）

Code block

```
1 # 设置密码
2 jupyter notebook password
3
4 # 后台启动 (断终端不挂)
5 nohup jupyter notebook --ip=0.0.0.0 --port=8888 --no-browser --allow-root >
  jupyter.log 2>&1 &
```

本地访问: `http://你的服务器IP:8888`

3. 训练代码注意事项

- 直接用系统预装的 `torch 2.4.1+cu124`，代码里 `device = torch.device('cuda')` 会自动识别 A100。
- 训练配置保持不变，**不需要改 CUDA 版本**。

4. 常用检查命令

Code block

```
1 # 看 GPU 状态
2 nvidia-smi
3
4 # 看 PyTorch 版本 + CUDA 可用性
5 python -c "import torch; print(torch.__version__, torch.cuda.is_available())"
6
7 # 看训练是否在跑
8 ps aux | grep python
9
10 # 杀死卡住的进程
11 pkill -f python
```

关键提醒

1. **不要重装 PyTorch**: 预装版本已经和 CUDA 12.4 完美适配，重装会引入版本冲突。
2. **MIG 必须关**: 每次重启实例都要先关 MIG，否则 `torch.cuda.is_available()` 会是 `False`。
3. **进度条不动 ≠ 卡死**: 第一次加载 192 万条数据，初始化 3~8 分钟是正常的。

(注：文档部分内容可能由 AI 生成)